

Rapport intermédiaire

Interprétabilité du prédicteur d'interactions phage-bactérie

Table des matières

1. Contexte et objectif	2
2. Travaux réalisés	3
2.1 Importance des modèles de fondations	3
2.1.1 Valeurs de Shapley (contribution marginale moyenne)	3
2.1.2 Ablations exhaustives	4
2.2 Validation MegaDNA-phage-bottom	5
2.3 Réduction dimensionnelle guidée par IG	6
2.4 Évaluation de la généralisation	7
2.5 Analyse XAI fine sur le modèle réduit (en cours)	8
a. Dims pro-infection et anti-infection	8
b. Dims hautement discriminatives	9
c. Waterfall IG par sample	10
3. Synthèse des résultats	11
4. Limites actuelles	11
5. Prochaines étapes	11
5.1 Recherche de patterns ADN qui maximisent une dim	11
5.2 Sparse Autoencoders sur les embeddings	11
5.3 Analyse jointe bact × phage	12
5.4 Reproduire l'analyse sur le best_model initial du projet	12
5.5 Cross-validation des attributions par SHAP	12
6. Livrables actuels	13
7. Travail à réaliser, dans l'ordre	13

1. Contexte et objectif

Le projet de base (PBIP) entraîne un classifieur binaire prédisant si un couple (bactérie, phage) donne lieu à une infection, à partir d'embeddings produits par plusieurs *foundation models* d'ADN (NT2, MegaDNA, DNABERT2). Le modèle complet de référence (best) concatène, pour chaque côté (phage / bactérie), les embeddings produits par les 3 foundation models, chacun avec sa propre **stratégie de merging** (truncate, top+bottom, max, TK-PERT...), avant de passer le tout à un MLP classifieur.

L'objectif de ce travail est de **comprendre ce que ce modèle apprend** :

1. quels foundation models contribuent réellement à la décision ?
2. quelles dimensions de leurs embeddings sont décisives ?
3. quelles propriétés de la séquence ADN expliquent l'activation de ces dimensions, et donc la prédiction d'infection ?

Le tout dans un cadre d'**explicabilité post-hoc** (XAI).

2. Travaux réalisés

2.1 Importance des modèles de fondations

Notebook : `model_importances_analysis.ipynb`

Afin de mieux comprendre le modèle et ses prédictions dans une optique d'**explicabilité**, j'ai voulu réaliser une forme de **feature selection** au niveau des foundation models : identifier ceux dont les embeddings portent réellement le signal de la décision, et écarter ceux qui n'ajoutent que du bruit.

Sur le modèle best étendu (NT2 + DNABERT2 + MegaDNA des deux côtés, **chaque modèle découpé en variantes Top / Bottom** quand sa stratégie de merging concatène first+last), j'ai mesuré la contribution de chaque (modèle, partie) au MCC, par deux méthodes complémentaires :

2.1.1 Valeurs de Shapley (contribution marginale moyenne)




Fig. 1. – Valeurs de Shapley par composant

Lecture : les trois plus gros contributeurs au MCC sont :

1. **MegaDNA (bactérie)** : de loin le plus important (≈ 0.20)
2. **NT2 (phage, partie top)** : ≈ 0.15
3. **MegaDNA (phage, partie bottom)** : ≈ 0.06

Les autres composants ont des valeurs de Shapley proches de zéro. Cela suggère que le modèle best est sur-paramétré : il utilise beaucoup de dimensions qui n'apportent pas d'information utile, et qui peuvent même ajouter du bruit.

2.1.2 Ablations exhaustives

En complément, j'ai ablaté des combinaisons de 5 modèles sur les 8 (ce qui isole chaque triplet restant) et j'ai mesuré le ΔMCC :




Fig. 2. – Ablations à 5 modèles, top 20 sur 56 combinaisons

Les pires dégradations ($\Delta\text{MCC} \approx -0.28$) sont les ablations qui retirent **MegaDNA-bact ET NT2-phage-top**. Les ablations qui retirent DNABERT2 ne dégradent pas (et améliorent parfois). Cohérent avec les Shapley.

Plus frappant : certaines configurations qui retirent **5 composants sur les 8** obtiennent un **MCC légèrement supérieur** à celui du modèle complet ($\Delta\text{MCC} \approx +0.02$). Autrement dit, garder seulement 3 composants suffit, et le modèle best est donc sur-paramétré : enlever les composants bruyants n'est pas neutre, c'est même bénéfique.

Conclusion 2.1 : MegaDNA-bact et NT2-phage-top sont les piliers. MegaDNA-phage-bottom est candidat sérieux comme troisième contributeur. DNABERT2 est négligeable.

2.2 Validation MegaDNA-phage-bottom

Notebook : `best_small_comparison.ipynb`

Les valeurs de Shapley suggèrent que MegaDNA-phage-bottom apporte un petit gain (≈ 0.06 de MCC marginal). Mais ces valeurs sont calculées sur un seul training : il faut vérifier que ce gain résiste au bruit de l'entraînement.

Procédure : deux architectures candidates entraînées **10 fois chacune** sur le split PredPhi train, évaluées sur deux jeux de test :

- **best_small2** : MegaDNA (bact, Truncate) + NT2 (phage, Truncate)
- **best_small3** : best_small2 + MegaDNA (phage, BottomTruncate)




Fig. 3. – best_small2 vs best_small3 sur 10 runs

Test	Métrique	best_small2	best_small3
PredPhi	MCC	0.55 $\pm$ 0.03	0.55 $\pm$ 0.03
PredPhi	F1	0.77 $\pm$ 0.02	0.78 $\pm$ 0.02
Généralisation (all)	MCC	0.33 $\pm$ 0.03	0.33 $\pm$ 0.02
Généralisation (all)	F1	0.58 $\pm$ 0.01	0.57 $\pm$ 0.01
Généralisation (all)	Précision	0.43 $\pm$ 0.01	0.42 $\pm$ 0.01
Généralisation (all)	Recall	0.88 $\pm$ 0.02	0.93 $\pm$ 0.02

Tableau 1. – Métriques moyennes $\pm$ std sur 10 runs

Constat : les deux configurations sont **essentiellement équivalentes** sur le MCC, à la fois sur PredPhi (0.55 vs 0.55) et sur la généralisation all (0.33 vs 0.33), avec un écart bien inférieur à l'écart-type entre runs. La seule différence systématique : best_small3 **gagne sur le recall** en généralisation (0.93 vs 0.88), mais **au prix de la précision** (0.42 vs 0.43) — c'est-à-dire un modèle plus biaisé vers le positif, sans réel gain discriminatif.

Conclusion 2.2 : l'ajout de MegaDNA-phage-bottom n'apporte pas de gain robuste. **Décision pour la suite** : on garde **uniquement MegaDNA (bact) + NT2 (phage)** = small2, plus simple et avec un MCC équivalent. Cette architecture est utilisée pour toute la suite des analyses XAI.

2.3 Réduction dimensionnelle guidée par IG

Notebook : `ig_dim_analysis.ipynb`

Maintenant que le modèle est ramené à **deux** foundation models (un côté bactérie : MegaDNA, un côté phage : NT2), on peut descendre d'un niveau et chercher, à l'intérieur de leurs embeddings, **quelles dimensions** portent réellement le signal de la décision. C'est une seconde passe de feature selection, cette fois au grain plus fin.

Sur `small2`, j'ai calculé les **Integrated Gradients** par sample (Captum, `n_steps=50`, baseline = embedding médian) pour identifier les dimensions qui portent l'information.

Pour choisir le seuil de coupure, j'ai balayé plusieurs valeurs entre 5 % et 100 % d'IG cumulé, et pour chaque seuil j'ai réentraîné 10 fois un classifieur sur les dims sélectionnées :




Fig. 4. – MCC sur le test set en fonction du % d'IG cumulé retenu (10 runs par point)

Lecture : le MCC monte rapidement entre 5 % et 30 % d'IG retenu, puis plateau au-delà. À partir de 30 % le score est déjà au pic (≈ 0.56) et n'augmente plus en gardant davantage de dims (et redescend même légèrement à 70–80 %). C'est le **meilleur compromis performance / nombre de dimensions** : on garde tout le signal utile sans le bruit ajouté par les dims peu informatives.

Résultat : à 30 % d'IG cumulé, j'ai retenu **69 dims bact + 125 dims phage = 194 dims** (au lieu de 1732, soit ≈ 11 % de `small2`). Le MCC est resté équivalent au modèle complet. Le modèle réduit a été sauvegardé sous `output/pbip/small2/ig30/`.

Pour mettre l'ordre de grandeur en perspective vis-à-vis du modèle best initial :

Modèle	Bact	Phage	Total	% de best
best	NT2 (768) + MegaDNA (964) + DNABERT2 (768) = 2 500	NT2 (1 536) + MegaDNA (1 928) + DNABERT2 (12 288) = 15 752	18 252	100 %
small2	MegaDNA = 964	NT2 = 768	1 732	≈ 9.5 %
small2_30ig	69	125	194	≈ 1 %

Tableau 2. – Cascade de réduction dimensionnelle

Soit une réduction d'un facteur $\approx 94\times$ entre best et `small2_30ig`, sans perte de MCC sur le set de test.

2.4 Évaluation de la généralisation

Notebook : models_comparison.ipynb

Maintenant que le modèle a été **fortement réduit** (de 18 252 à 194 dimensions, soit $\approx 1\%$ du best initial), il faut vérifier que cette compression n'a rien sacrifié. Deux questions à trancher :

1. Les performances **en moyenne** (sur plusieurs runs, pour neutraliser le bruit du training) restent-elles équivalentes au modèle complet ?
2. Le modèle réduit **généralise-t-il** aussi bien hors-distribution ?

Pour y répondre, j'entraîne **10 fois chaque architecture** (best, small2, small2_30ig) sur le train PredPhi, puis j'évalue sur deux jeux de test : PredPhi-test (in-distribution) et le dataset externe all (7720 couples, out-of-distribution). On compare ensuite **moyenne $\pm$ std** sur les 10 runs.




Fig. 5. – Comparaison des 3 modèles

Modèle	MCC	F1	Accuracy	Précision	Rappel
best	-0.17 ± 0.04	0.26 ± 0.01	0.45 ± 0.04	0.23 ± 0.01	0.30 ± 0.03
small2	0.31 ± 0.02	0.57 ± 0.01	0.56 ± 0.02	0.42 ± 0.01	0.90 ± 0.02
small2_30ig	0.31 ± 0.03	0.57 ± 0.01	0.57 ± 0.03	0.42 ± 0.02	0.89 ± 0.02

Tableau 3. – Métriques sur le dataset all (moyenne $\pm$ std sur 10 runs)

Résultat : le modèle best (le plus gros) **ne généralise pas** sur le dataset externe (MCC négatif, équivalent à pire qu'aléatoire). Le modèle small2, avec seulement 2 foundation models, généralise nettement mieux. Cohérent avec 2.1 : DNABERT2 ajoute du bruit qui sur-spécialise le modèle au split d'entraînement PredPhi. Le modèle réduit small2_30ig (194 dims) fait aussi bien que small2 (1732 dims) : les 194 dims retenues portent l'essentiel du signal de généralisation.

2.5 Analyse XAI fine sur le modèle réduit (en cours)

Notebook : ig_dim_analysis_30ig.ipynb

Maintenant que le modèle a été ramené à 194 dimensions effectives sans perte de performance, on dispose d'une **surface d'attribution beaucoup plus réduite** à analyser : chaque dimension restante est, par construction, une de celles qui portent réellement le signal. C'est le bon moment pour passer à une **explicabilité plus précise**, qui aurait été beaucoup plus difficile à mener sur les 1732 dimensions de `small2` (signal noyé dans le bruit) ou sur les 18 252 du modèle best complet (intractable et trompeur).

Sur le modèle final `small2_30ig` (194 dims), j'ai recalculé les IG, **cette fois signés et ciblant la classe infection** (auparavant je regardais $|IG|$, ce qui mélangeait pro et anti).

a. Dims pro-infection et anti-infection

- **Pro-infection** : dims avec IG signé moyen sur les TP le plus positif, c'est-à-dire des dims dont la valeur observée sur les vrais positifs pousse le modèle à dire « infection ».
- **Anti-infection** : dims avec IG signé moyen sur les TN le plus négatif, c'est-à-dire des dims dont la valeur observée sur les vrais négatifs fait baisser prob(infection).




Fig. 6. – Top 20 dimensions pro-infection (gauche, IG signé moyen sur les TP) et anti-infection (droite, IG signé moyen sur les TN), côté bactérie (haut) et phage (bas)

Lecture : les barres bleues / oranges (gauche) montrent les dims qui **poussent** le modèle vers la classe « infection » sur les vrais positifs, les barres rouges / violettes (droite) montrent celles qui **retiennent** le modèle vers la classe « non-infection » sur les vrais négatifs.

b. Dims hautement discriminatives

Certaines dims apparaissent **dans les deux classements** (top pro et top anti) : ex. bact dim 31 a $IG_{TP} = +0.053$ et $IG_{TN} = -0.065$. Ça signifie que la **valeur** de la dim diffère systématiquement entre samples positifs et négatifs, et que le modèle s'appuie dessus comme axe discriminatif principal.

Exemple, bact dim 31 : l'histogramme (gauche) et le boxplot (droite) montrent la distribution de la valeur de la dim selon l'outcome.




Fig. 7. – Distribution de bact dim 31 par outcome

La séparation TP / TN n'est **pas franche visuellement** sur l'histogramme (les deux distributions se chevauchent largement), mais on observe quand même une **tendance nette** : davantage de TP dans la partie gauche (valeurs négatives), et les **médianes des boxplots** le confirment, $TP \approx -1.2$ contre $TN \approx -0.3$. C'est attendu : une dim seule ne suffit généralement pas à trancher, c'est la **combinaison** de plusieurs dims discriminatives qui produit la décision finale.

À noter sur le boxplot : les distributions s'alignent sur le **vrai label** plutôt que sur la prédiction. TP et FN (label=1) ont des médianes proches et plus basses ; TN et FP (label=0) plus hautes. Les erreurs (FP, FN) sont concentrées dans la **zone ambiguë** au milieu, là où la dim seule ne tranche pas, et où d'autres dims peuvent renverser la décision.

Limite biologique importante : analyser bact dim 31 (ou n'importe quelle dim) **isolément** ne fait pas réellement sens biologiquement. L'infection est une **propriété conjointe** du couple bact × phage . L'IG donne des attributions marginales par dim de chaque côté, mais le vrai signal pro-infection est probablement dans **l'interaction** entre certaines dims bact et certaines dims phage. Ce que l'analyse univariée ci-dessus identifie comme « dim pro-infection » est une approximation : la vraie réponse demande une analyse jointe (voir section 5.3).

Toutefois, **toutes les bactéries ne sont pas égales face à l'infection** : certaines sont très permissives et sont infectées par beaucoup de phages, tandis que d'autres sont quasi inattaquables. Une dim bact pro-infection comme dim 31 pourrait donc en partie **encoder l'identité** d'une bactérie fortement susceptible.

c. Waterfall IG par sample

Pour comprendre **un cas précis** plutôt qu'une moyenne, j'ai tracé pour 4 samples représentatifs (TP / TN / FP / FN les plus confiants) la contribution signée de chaque dim. Cela permet de voir :

- quels couples bact × phage activent fortement les dims pro-infection
- où se situent les faux positifs : quelles dims les ont trompés
- l'équilibre entre contribution bactérie vs phage par sample

Exemple sur un TP très confiant (sample idx=1062, prob(infection)=0.996) :




Fig. 8. – Waterfall IG pour un TP

On retrouve bien la **dim 31 (orig 414)** déjà identifiée comme top pro-infection dans la section 2.5 b : sa contribution IG est ici clairement positive ($\approx +0.04$) et tire la prédiction vers l'infection. Les dims 35, 1 et 33 (toutes dans le top pro-infection global) tirent aussi dans le même sens. Côté phage, les top dims pro-infection identifiées (92, 90, 33) sont également présentes et positives.

3. Synthèse des résultats

1. **Sur-paramétrisation néfaste** : best (3 foundation models) a des résultats **à peine inférieurs** à small2 sur le test set PredPhi (in-distribution, scores très proches), mais s'effondre complètement en généralisation sur all (MCC fortement négatif). small2 tient le coup dans les deux cas et généralise nettement mieux.
2. **Choix d'architecture validé** : l'ajout d'une 3ème variante d'embedding (MegaDNA-phage-bottom) n'apporte pas de gain robuste sur 10 runs, on s'en tient à MegaDNA-bact + NT2-phage.
3. **Compressibilité forte** : le modèle complet best utilisait **18 252 dimensions** au total (2500 bact + 15 752 phage, dont DNABERT2-phage à lui seul = 12 288). small2 n'en garde que **1732** ($\approx 9.5\%$ du total), et small2_30ig réduit encore à **194 dims** ($\approx 11\%$ de small2, et $\approx 1\%$ du modèle initial). La majorité du signal exploitable est portée par quelques dizaines de dims.
4. **Asymétrie bact/phage** : les bactéries (MegaDNA) ont moins de dims retenues (69) mais avec des IG signés plus forts par dim (top dim bact = +0.05) que le phage (top dim phage = +0.03). Côté bact, la décision est plus concentrée.
5. **Dims discriminatives identifiées** : quelques dims (bact 31, 33, 35 ; phage 115, 87, 100) portent l'essentiel du signal pro/anti-infection.

4. Limites actuelles

- **NT2 et MegaDNA** n'ont pas été conçus pour être interprétables par dimension. Chaque dim mélange potentiellement plusieurs concepts biologiques. Une dim « pro-infection » n'a probablement pas une signification biologique unique.
- **Aucun papier** ne mappe les dimensions individuelles de NT2 ou MegaDNA à des features biologiques précises.

5. Prochaines étapes

5.1 Recherche de patterns ADN qui maximisent une dim

Idee centrale : pour une dimension donnée d (par exemple bact dim 31 = la plus pro-infection), trouver **quelles séquences ADN maximisent la valeur de cette dim** dans l'embedding du foundation model.

Trois approches praticables :

- **Sliding window** : prendre une séquence bactérienne réelle, faire glisser une fenêtre de taille fixe, recalculer l'embedding, mesurer la chute de la dim d . Les fenêtres qui font le plus chuter sont celles qui *contiennent* le motif responsable.
- **Sélection par dataset** : parmi les séquences bactériennes, identifier celles qui ont la valeur de dim d la plus élevée, et faire une analyse de motifs classique sur leurs régions ADN.
- **Génération adverse** : optimiser une séquence ADN par rapport à la dim d via un algorithme génétique ou une descente de gradient.

5.2 Sparse Autoencoders sur les embeddings

Un problème connu des embeddings de modèles comme NT2 est la superposition : une même dimension encode plusieurs concepts biologiques à la fois (GC, longueur, motifs...), ce qui rend l'interprétation difficile. L'idée d'utiliser un Sparse Autoencoder (SAE) est de forcer le modèle à re-exprimer ces embeddings dans un dictionnaire plus grand, où chaque « feature » est idéalement monosémantique, c'est-à-dire associée à un seul concept. En pratique, on entraînerait un SAE (dict size $\approx 512-4096$) sur les embeddings de small2_30ig et on vérifierait si les features obtenues corrélaient mieux avec les annotations biologiques que les dimensions brutes. Cette approche n'est pas nouvelle : Anthropic l'a montrée sur des LLM textuels (Bricken et al., Towards Monosemanticity, 2023), et Decode-gLM (2025) l'a reproduite sur le Nucleotide Transformer avec des résultats encourageants [<https://www.biorxiv.org/content/10.1101/2025.10.31.685860v1>]. Pour les phages, ça reste à explorer, les génomes sont mal annotés, donc il est difficile de savoir à l'avance si une feature SAE correspondrait à quelque chose de biologiquement interprétable comme le tropisme hôte, ou simplement à un artefact du pré-entraînement.

5.3 Analyse jointe bact × phage

Jusqu'ici je regarde les dims pro-infection côté bact, puis côté phage, chacune dans son coin. Or l'infection arrive quand un phage donné est compatible avec une bactérie donnée : une dim bact « pro-infection » ne veut probablement rien dire toute seule, elle compte surtout en combinaison avec certaines dims phage.

Une piste simple à essayer : prendre les top dims de chaque côté (par exemple les 10 plus pro-infection bact et les 10 plus pro-infection phage), former toutes les paires possibles (bact_i, phage_j), et regarder sur les TP si la valeur de bact_i × phage_j est plus élevée que sur les TN. Si oui, c'est qu'il y a bien un effet d'interaction entre ces deux dims, et pas juste une somme d'effets indépendants.

5.4 Reproduire l'analyse sur le best_model initial du projet

Au démarrage du projet, l'architecture de référence n'était pas le best utilisé dans ce rapport, mais un autre best_model avec des **choix de stratégie de merging différents** (autres combinaisons de truncate / top+bottom / TK-PERT...) et **une couche de PCA en amont du classifieur** pour réduire les embeddings concaténés avant le MLP.

Il serait intéressant de **rejouer toute la chaîne d'analyse XAI** (Shapley et ablation des composants, IG par dim, sélection guidée par IG, caractérisation des dims pro/anti-infection) sur ce best_model initial, puis de vérifier si on arrive aux **mêmes conclusions** :

- est-ce que MegaDNA-bact et NT2-phage ressortent toujours comme piliers, ou est-ce que les stratégies de merging changent la donne ?
- est-ce que la concentration de l'IG dans ≈ 10 % des dims tient encore avec une couche de PCA en amont ?
- est-ce que les dims pro-infection identifiées correspondent (après remontée à travers la PCA) à des notions biologiques cohérentes avec ce qu'on a trouvé sur small2 ?

Si les conclusions tiennent, c'est une preuve que les résultats sont robustes au choix de l'architecture exacte. Sinon, cela indique que les conclusions dépendent du pipeline et qu'il faut nuancer.

5.5 Cross-validation des attributions par SHAP

Lancer SHAP (DeepExplainer ou KernelSHAP) sur les mêmes samples que les waterfall IG. Si les deux méthodes désignent les mêmes dims comme pro-infection sur les mêmes samples, la robustesse est confirmée.

6. Livrables actuels

Fichier	Description
output/pbip/small2/	Modèle small2 (MegaDNA bact + NT2 phage) + config
output/pbip/small2/ig30/	Modèle small2_30ig (194 dims) + indices des dims retenues
output/pbip/best_small3/	Modèle entraîné pour la comparaison 2.2 (variante avec MegaDNA-phage-bottom)
analysis/model_importances_analysis.ipynb	Shapley + ablations des composants
analysis/best_small_comparison.ipynb	small2 vs small3, 10 runs × 2 datasets
analysis/models_comparison.ipynb	Comparaison best vs small2 vs small2_30ig sur all
analysis/ig_dim_analysis.ipynb	Réduction par IG vers small2_30ig
analysis/ig_dim_analysis_30ig.ipynb	Analyse XAI fine du modèle réduit (en cours)

7. Travail à réaliser, dans l'ordre

1. **Analyse jointe bact × phage** : passer des attributions marginales à une vraie analyse d'interactions de paires de dims (cf. section 5.3).
2. **Reproduire l'analyse sur le best_model initial** (autres stratégies de merging + couche PCA) pour vérifier que les conclusions tiennent en dehors du pipeline small2 (cf. section 5.4).
3. **Finaliser ig_dim_analysis_30ig.ipynb** : corrélations dim / ADN complètes, features supplémentaires (entropie, codon usage, sites de restriction).
4. **Recherche de patterns ADN qui maximisent une dim** : sliding window / occlusion sur quelques séquences (cf. section 5.1).
5. **POC Sparse Autoencoder** sur les embeddings + comparaison avec les dims brutes (cf. section 5.2).
6. **SHAP en cross-validation** des attributions IG sur quelques samples (cf. section 5.5).
7. **Rédaction finale du rapport de TB.**